

基于声音的鸟类识别系统

徐圣童¹

(1. 南京师范大学计算机与电子信息/人工智能学院, 江苏 南京 210023)

摘要: 该文基于 BirdCLEF 2026 数据集, 构建了一套完整的基于声音的鸟类识别系统。首先对音频进行预处理(重采样至 22050 Hz、截取/填充至 5 s), 提取包括梅尔频率倒谱系数(Mel-frequency Cepstral Coefficient, MFCC)及其一阶、二阶差分、基频(F0)、均方根能量(Root Mean Square, RMS)、频谱质心/带宽/滚降/平坦度和过零率(Zero Crossing Rate, ZCR)共 278 维声学特征。在此基础上分别构建了 K 近邻(K-Nearest Neighbor, KNN)、支持向量机(Support Vector Machine, SVM)、随机森林(Random Forest, RF)等传统机器学习模型, 以及基于对数梅尔频谱图的卷积神经网络(Convolutional Neural Network, CNN)和基于 MFCC 序列的双向长短期记忆网络(Bidirectional Long Short-Term Memory, BiLSTM)深度学习模型, 共 5 种模型。实验结果表明, CNN 模型取得最优性能, 测试集准确率为 48.75%, 宏平均 F1 分数(Macro F1)为 0.463, 优于其他所有模型。深度学习整体优于传统机器学习方法, 验证了端到端特征学习的有效性。最后, 该文使用 Gradio 构建了 Web 交互界面, 支持实时音频上传与多模型识别结果展示。

关键词: 鸟类识别; 声音识别; 梅尔频率倒谱系数; 卷积神经网络; 双向长短期记忆网络

中图分类号: TP391

文献标识码: A

Bird Species Recognition System Based on Sound

Choi Seng Tong¹

(1. School of Computer and Electronic Information/School of Artificial Intelligence, Nanjing Normal University, Nanjing 210023, China)

Abstract: This paper presents a bird sound recognition system based on the BirdCLEF 2026 dataset. Audio clips are preprocessed by resampling to 22050 Hz and padding/trimming to 5 s. A 278-dimensional acoustic feature vector is extracted, including MFCCs with first- and second-order deltas, fundamental frequency (F0), RMS energy, spectral centroid/bandwidth/rolloff/flatness, and zero-crossing rate (ZCR). Three traditional machine learning models (KNN, SVM, Random Forest) and two deep learning models—CNN on log-Mel spectrograms and BiLSTM on MFCC sequences—are constructed and compared. Experimental results show that CNN achieves the best performance with 48.75% test accuracy and a Macro F1 score of 0.463. Deep learning methods outperform traditional ML methods overall, validating the effectiveness of end-to-end feature learning. A Gradio-based web interface is also developed for real-time bird sound recognition.

Key words: bird recognition; sound recognition; MFCC; CNN; BiLSTM

0 引言

鸟类是生态系统健康的重要指示物种, 其多样性监测对生物保护具有重要意义。传统人工野外调查效率低、成本高, 难以大规模部署。近年来, 被动声学监测技术的兴起使得自动化鸟鸣识别成为可能 [1]。基于机器学习的鸟鸣识别系统已在生物多样性调查中展现出广阔的应用前景。

BirdCLEF 2026 是 Kaggle 举办的国际鸟类声音识别竞赛, 提供了来自南美洲热带地区的大规模

野外鸟鸣录音数据集 [2]。该文基于此数据集, 综合运用传统机器学习与深度学习方法构建多模型对比系统, 并提供 Web 交互界面, 旨在探索不同特征表示与模型结构对鸟鸣识别性能的影响。

1 数据集与预处理

1.1 数据集

BirdCLEF 2026 数据集收录了鸟类 (Aves)、两栖类、爬行类等多种生物的声音录音, 音频格式

为.ogg，来源包括 iNaturalist 和 Xeno-canto 平台。该文从中筛选鸟类样本，选取样本数量最多的 20 个物种进行实验，共涵盖 Osprey（鱼鹰）、Tropical Screech Owl（热带鸣角鸮）等 20 种鸟类。每类深度学习最多取 100 条、传统机器学习最多取 50 条，共约 1600 条训练样本（见表 1）。

表 1 数据集配置

属性	说明
音频格式	.ogg（重采样至 22050 Hz，单声道）
识别类别数	20 种鸟类（Aves）
深度学习样本	每类 ≤ 100 条，共 ≈ 1600 条
传统 ML 样本	每类 ≤ 50 条，共 ≈ 800 条
单条音频时长	5s（零填充/截断）
数据划分	训练/验证/测试 = 8:1:1（分层）

1.2 预处理

- （1）重采样：使用 librosa 将所有音频统一重采样至 22050 Hz；
- （2）单声道：立体声混合为单声道；
- （3）时长标准化：截取或零填充至固定 5s（110250 采样点）；
- （4）数据划分：按 8:1:1 比例进行分层随机划分，保证各子集中各类别比例一致。

2 特征提取

2.1 传统机器学习特征向量（278 维）

对每条 5s 音频计算以下声学特征在时间轴上的均值与标准差，拼接成 278 维固定长度特征向量（见表 2）。

表 2 传统机器学习特征构成（278 维）

特征类别	描述	维度
MFCC+ Δ + Δ^2	40 阶及一、二阶差分（均值 + 标准差）	240
Chroma	12 维色度特征	24
频谱形状	质心、带宽、滚降点、平坦度	8
ZCR	过零率，反映鸣叫速率	2
RMS	均方根能量，反映音量	2
F0 (YIN)	基频，反映音高，32-2048 Hz	2
合计		278

MFCC 是从梅尔滤波器组输出的对数能量经离散余弦变换得到的倒谱系数，能够有效压缩频谱的时频包络信息 [3]。音高（pitch）使用 YIN 算法 [4] 从基频轨迹估计，仅对有声帧（ $f_0 > 0$ ）统计均值与标准差，静音帧置零。

核心特征提取代码如下：

Listing 1 特征提取核心代码（utils.py 节选）

```

1 def extract_features(y, sr=22050):
2     mfcc = librosa.feature.mfcc(
3         y=y, sr=sr, n_mfcc=40,
4         n_fft=2048, hop_length=512)
5     delta1 = librosa.feature.delta(mfcc)
6     delta2 = librosa.feature.delta(mfcc, order=2)
7     feats = []
8     for mat in (mfcc, delta1, delta2):
9         feats.extend(mat.mean(axis=1))
10        feats.extend(mat.std(axis=1))
11    # 音高 F0 (YIN)
12    f0 = librosa.yin(y, fmin=32, fmax=2048,
13                    sr=sr, hop_length=512)
14    f0v = f0[f0 > 0]
15    feats += [float(f0v.mean()) if len(f0v) else 0.,
16            float(f0v.std()) if len(f0v) else 0.]
17    return np.array(feats, dtype=np.float32)

```

2.2 CNN 输入：对数梅尔频谱图

参数设置 $n_mels = 128$ 、 $n_fft = 2048$ 、 $hop_length = 512$ ，计算对数梅尔频谱图并固定为 212 帧，归一化至 [0,1]，形状为 (1,128,212)。

2.3 BiLSTM 输入：MFCC 时序矩阵

提取 40 阶 MFCC 时序序列，对每个倒谱系数独立进行 z-score 标准化，固定为 212 帧，形状为 (212,40)，保留鸣声随时间变化的动态信息。

图 1 展示了典型鸟鸣音频的多种特征可视化结果。

3 模型构建

3.1 传统机器学习模型

三种传统模型均以 278 维特征向量为输入，训练前经 StandardScaler 标准化，采用 5 折分层交叉验证（StratifiedKFold）结合 GridSearchCV 进行超参数搜索。

KNN：通过欧氏距离寻找 K 个最近邻居进行多数投票，网格搜索 $K \in \{3,5,7,9\}$ 及距离权重策略 [5]。




图 1 鸟鸣音频波形、梅尔频谱、MFCC 与色度图

SVM: 使用 RBF 核将特征映射至高维空间，寻找最大间隔决策超平面，网格搜索 $C \in \{0.1, 1, 10\}$ 和 $\gamma \in \{\text{scale}, \text{auto}\}$ [6]。

随机森林 (RF): 集成多棵决策树，每棵树用 Bootstrap 样本和随机子特征训练，最终多数投票，有效缓解过拟合 [7]。

3.2 卷积神经网络 (CNN)

以对数梅尔频谱图作为二维图像输入。网络由 4 个卷积块构成，结构为 Conv2d-BN-ReLU $\times 2$ + MaxPool + Dropout，通道数依次为 32 $\rightarrow$ 64 $\rightarrow$ 128 $\rightarrow$ 256。之后接 AdaptiveAvgPool2d(4 $\times$ 4) 和全连接分类头 (4096 $\rightarrow$ 512 $\rightarrow$ 256 $\rightarrow$ 20)。训练采用 AdamW 优化器 ($lr = 10^{-3}$, $\text{weight_decay} = 10^{-4}$)、CosineAnnealingLR 学习率调度和 WeightedRandomSampler 处理类别不平衡，以验证集准确率为指标进行早停 ($\text{patience}=7$) [9]。

Listing 2 CNN 模型结构 (04_cnn_model.py 节选)

```
1 class BirdCNN(nn.Module):
2     def __init__(self, n_classes):
3         super().__init__()
4         self.features = nn.Sequential(
5             nn.Conv2d(1, 32, 3, padding=1),
6             nn.BatchNorm2d(32), nn.ReLU(),
7             nn.Conv2d(32, 32, 3, padding=1),
8             nn.BatchNorm2d(32), nn.ReLU(),
9             nn.MaxPool2d(2, 2), nn.Dropout2d(0.1),
10            # ... (共4个卷积块)
11            nn.AdaptiveAvgPool2d((4, 4)),
12        )
13        self.classifier = nn.Sequential(
14            nn.Flatten(),
15            nn.Linear(256*4*4, 512), nn.ReLU(),
16            nn.Dropout(0.5),
17            nn.Linear(512, 256), nn.ReLU(),
```

```
18         nn.Dropout(0.3),
19         nn.Linear(256, n_classes),
20     )
```

3.3 双向长短时记忆网络 (BiLSTM) + 注意力机制

将 MFCC 时序矩阵作为序列输入，通过双向长短时记忆网络 (Bidirectional LSTM) [8] 同时建模正向与反向时序依赖。引入注意力机制 (Attention) 对各时刻隐状态加权聚合，突出关键鸣叫片段 ($\text{hidden_size}=128$, 2 层, $\text{dropout}=0.3$)，全连接头为 256 $\rightarrow$ 128 $\rightarrow$ 20。

注意力聚合计算如式 (1):

$$\mathbf{c} = \sum_{t=1}^T \alpha_t \mathbf{h}_t, \quad \alpha_t = \frac{\exp(\mathbf{w}^\top \mathbf{h}_t)}{\sum_{j=1}^T \exp(\mathbf{w}^\top \mathbf{h}_j)} \quad (1)$$

其中 $\mathbf{h}_t$ 为第 t 时刻双向 LSTM 的隐状态， $\mathbf{w}$ 为可学习参数向量。

4 实验结果与分析

4.1 传统机器学习结果

表 3 给出了三种传统机器学习模型在 5 折交叉验证和独立测试集上的性能。SVM 取得最优结果，测试集准确率 36%，Macro F1 为 0.355。KNN 性能最差 (22%)，主要原因是 278 维高维特征空间中距离集中现象降低了近邻搜索的区分度。

表 3 传统机器学习模型性能对比

模型	CV 均值	CV 标准差	测试准确率	Macro F1
KNN	18.75%	$\pm 1.48\%$	22.00%	0.209
SVM	33.13%	$\pm 1.63\%$	36.00%	0.355
RF	29.88%	$\pm 3.15\%$	32.50%	0.314

4.2 深度学习结果

表 4 为两种深度学习模型的性能。CNN 以 48.75% 的测试准确率成为所有模型中最优者，BiLSTM 以 38.75% 紧随其后。

图 3 展示了 CNN 的训练曲线，验证集准确率在约第 15 个 epoch 后趋于稳定，早停机制有效防止了过拟合。




图 2 SVM 混淆矩阵（测试集，20 类）

表 4 深度学习模型性能对比

模型	测试准确率	Macro F1	输入
CNN	48.75%	0.463	梅尔频谱图 (1×128×212)
BiLSTM	38.75%	0.385	MFCC 序列 (212×40)

4.3 综合对比与分析

表 5 给出了 5 种模型的综合排名，图 5 为对比柱状图。

表 5 五种模型综合性能排名

排名	模型	类型	测试准确率	Macro F1
1	CNN	深度学习	48.75%	0.463
2	BiLSTM	深度学习	38.75%	0.385
3	SVM	传统 ML	36.00%	0.355
4	RF	传统 ML	32.50%	0.314
5	KNN	传统 ML	22.00%	0.209

深度学习整体优于传统机器学习，原因在于 CNN 和 BiLSTM 能够直接从原始时频表示中自动学习判别特征，而传统机器学习依赖手工统计特征，丢失了大量时序结构信息。CNN 优于 BiLSTM，是因为对数梅尔频谱图保留了完整的二维时频结构，卷积核可高效捕获局部时频模式。

整体准确率偏低的主要原因：（1）每类训练样本仅 50–100 条，深度模型难以充分拟合；（2）部分物种鸣声频率相似，区分难度较高（由混淆矩阵可见 Osprey 与 Tropical Screech Owl 之间存在明显混




图 3 CNN 训练曲线（损失与准确率随训练轮次的变化）




图 4 CNN 混淆矩阵（测试集，20 类）

淆）；（3）实验在 CPU 上进行，模型规模和训练轮数受限。

5 用户界面

该文使用 Gradio 4.x 构建了基于 Web 的交互式识别界面，支持上传.ogg/.wav/.mp3 格式鸟鸣录音，一键运行全部 5 个模型并同时展示结果。界面主要包含：（1）音频上传与播放区；（2）音频可视化面板（波形/对数梅尔频谱/MFCC 三合一图）；（3）声学特征摘要（时长/平均音高/音量/过零率）；（4）各模型 Top-5 物种识别结果与置信度百分比。运行命令为 `python 06_ui.py`，访问 <http://localhost:7860>。

6 结论

该文基于 BirdCLEF 2026 数据集实现了完整的鸟类鸣声识别系统，涵盖数据预处理、278 维多维声学特征提取、5 种模型（KNN/SVM/RF/CNN/BiLSTM）的构建与对比，以及 Web 交互界面。实验表明 CNN（48.75%）取得




图 5 五种模型测试集准确率与 Macro F1 综合对比

最优性能，深度学习整体优于传统机器学习。未来可通过以下方式进一步提升识别准确率：（1）对训练音频施加时间拉伸、音调偏移、噪声叠加等数据增强；（2）引入预训练音频模型（如 BirdNET [10]）进行迁移学习；（3）对 CNN、BiLSTM、SVM 三模型的预测概率进行加权融合；（4）引入 Transformer 等更强序列建模结构。

参考文献

- [1] Stowell D, Wood M D, Pamula H, et al. Automatic acoustic detection of birds through deep learning: the first Bird Audio Detection challenge[J]. *Methods in Ecology and Evolution*, 2019, 10(3): 368–380.
- [2] BirdCLEF 2026 Competition[EB/OL]. [2026-06-01]. <https://www.kaggle.com/competitions/birdclef-2026>.
- [3] Davis S, Mermelstein P. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences[J]. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 1980, 28(4): 357–366.
- [4] De Cheveigné A, Kawahara H. YIN, a fundamental frequency estimator for speech and music[J]. *The Journal of the Acoustical Society of America*, 2002, 111(4): 1917–1930.
- [5] Cover T, Hart P. Nearest neighbor pattern classification[J]. *IEEE Transactions on Information Theory*, 1967, 13(1): 21–27.
- [6] Cortes C, Vapnik V. Support-vector networks[J]. *Machine Learning*, 1995, 20(3): 273–297.
- [7] Breiman L. Random forests[J]. *Machine Learning*, 2001, 45(1): 5–32.
- [8] Hochreiter S, Schmidhuber J. Long short-term memory[J]. *Neural Computation*, 1997, 9(8): 1735–1780.
- [9] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]// *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. Las Vegas: IEEE, 2016: 770–778.
- [10] Kahl S, Wood C M, Eibl M, et al. BirdNET: A deep learning solution for avian diversity monitoring[J]. *Ecological Informatics*, 2021, 61: 101236.
- [11] McFee B, Raffel C, Liang D, et al. librosa: Audio and music signal analysis in python[C]// *Proceedings of the 14th Python in Science Conference*. Austin: SciPy, 2015: 18–25.